

RELATÓRIO TÉCNICO: PREVISÃO DE QUALIDADE DO AR

Instituição: UNIMAR

Curso: Inteligência Artificial

Disciplina: Algoritmos de Inteligência Artificial (classificadores)

Docente: Ma. Nathalia A. Lima

Integrantes do Grupo 6:

Felipe Augusto Santos Dorta de Oliveira (RA: 2052799)

Bruno Marcelo Rocha da Silva (RA: 1988442)

Lucas de Azevedo Kopeska Paraizo (RA: 2054984)

Repositório: <https://github.com/Lucas-Kopeska/PREVISAO-DE-QUALIDADE-DO-AR>

1. Introdução e Contextualização

O presente relatório tem como finalidade a exposição das etapas do modelo de classificação desenvolvido para classificar a qualidade do ar como “boa” ou “ruim”, baseando-se no dataset *Air Quality* disponibilizado via Kaggle. O projeto visa não apenas a construção de um pipeline preditivo robusto, mas também o seu deploy funcional em uma aplicação web streamlit, permitindo inferências em tempo real para tomada de decisão ambiental.

Este documento detalha as melhorias implementadas na fase P2 do projeto, corrigindo fragilidades analíticas da P1, principalmente em questão à construção do relatório, aprofundando a interpretabilidade dos algoritmos de *Machine Learning* e avaliando a consistência do modelo diante de variações climáticas sazonais.

2. Análise Exploratória de Dados (EDA) e Pré-processamento

A fase de pré-processamento é crítica para evitar o enviesamento dos algoritmos. Conforme expresso no kaggle, o valor “-200” no dataset indicam valores nulos, logo, foi necessário apontar como esses valores estavam distribuídos ao longo do dataset. O resultado obtido foi que as features preditoras CO(GT), NOx(GT) e NO2(GT) indicaram cerca de 17% de valores faltantes, enquanto NMHC(GT) indicou 89%. As outras colunas apresentaram porcentagem baixa em torno de 4%. Variáveis com excesso crítico de ausência (como NMHC(GT)) foram desconsideradas, e para as demais foi aplicada a imputação adequada. Para garantir que a escala de sensores distintos não dominasse o gradiente de convergência dos algoritmos, aplicou-se a normalização dos dados utilizando o StandardScaler. Essa técnica padroniza as features para que possuam média 0 e desvio padrão 1, o que é estritamente necessário para algoritmos sensíveis a distâncias espaciais, como o KNN.

Foi realizada também uma rigorosa Engenharia de Features Temporais. A data da coleta foi decomposta em “Mês”, “Dia da Semana” e “Estação do Ano”, permitindo ao modelo capturar padrões cíclicos de poluição decorrentes da atividade humana (ex: horários de pico e dias úteis) e fenômenos meteorológicos.

3. Metodologia de Modelagem e Avaliação (P1)

Na primeira iteração do projeto, o conjunto de dados foi estratificado em treino e teste e submetido a três algoritmos distintos: K-Nearest Neighbors (KNN), Random Forest e Gradient Boosting.

A fim de garantir a validade estatística dos resultados e mitigar viés de particionamento, implementou-se a Validação Cruzada Estratificada com 5 *folds* (K=5). Após a revisão da P1, notou-se um comportamento anômalo: o algoritmo Random Forest obteve uma acurácia de 1.000 (100%) nos dados de treino, o que configura um sinal de *overfitting*. O modelo havia decorado os padrões do conjunto de treinamento em vez de aprender as regras de generalização.

4. Evolução e Otimização de Hiperparâmetros (P2)

Para corrigir o cenário de *overfitting* da P1 e consolidar um modelo resiliente, aplicou-se a técnica de GridSearchCV sobre o Random Forest. O objetivo do GridSearch é buscar, de forma combinatória, os hiperparâmetros ideais para restringir o crescimento excessivo das árvores de decisão.

Para a otimização dos hiperparâmetros, utilizamos inicialmente os seguintes valores:

- 'n_estimators': [100, 200, 300]
- 'max_depth': [10, 15, 20, None]
- 'min_samples_split': [2, 5, 10]
- 'min_samples_leaf': [1, 2, 4]

Porém, esse espaço amostral foi danoso ao modelo, já que a Acurácia despencou para 52.56% e a Precisão, Recall e F1-Score foram para 0.0000. Isso significa que o GridSearchCV escolheu hiperparâmetros que inviabilizaram o modelo. Restrições muito agressivas (como um max_depth muito baixo ou um min_samples_leaf muito alto) causaram um subajuste severo (*underfitting*), fazendo com que as árvores não conseguissem aprender nada e virassem apenas nós de decisão genéricos chutando a classe majoritária.

Após o diagnóstico desse problema, recalibramos a grade do GridSearch para conceder a flexibilidade exata que o modelo necessitava:


- 'n_estimators': [100, 150, 200]
- 'max_depth': [15, 20, None]
- 'min_samples_split': [2, 5]
- 'min_samples_leaf': [1, 2]

Essa calibração técnica eliminou tanto o *overfitting* do modelo base quanto o *underfitting* da primeira otimização. Ele se consolidou como o verdadeiro campeão de generalização.

5. Resultados Finais e Comparação de Desempenho


A tabela abaixo evidencia o salto de estabilidade estatística do ecossistema ao comparar os modelos base com o Random Forest Otimizado (P2):

Classificador	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
KNN	0.9194	0.9253	0.9029	0.9140	0.9753
Gradient Boosting	0.9309	0.9233	0.9317	0.9275	0.9827
Random Forest (P1)	0.9370	0.9370	0.9290	0.9330	0.9850
Random Forest (Otimizado P2)	0.9395	0.9363	0.9363	0.9363	0.9856




O F1-Score do Random Forest Otimizado subiu para 0.9363 (superando os 0.9275 do Gradient Boosting e os 0.9140 do KNN). A métrica de AUC-ROC atingiu 0.9856, mostrando um poder quase perfeito de separação entre as classes de ar "bom" e "ruim".

5.1 Análise Gráfica: Matriz de Confusão e Curva ROC




A Matriz de Confusão evidencia o alto rigor do modelo. O baixo número de Falsos Positivos garante que a população não receberá alarmes indevidos de poluição (evitando pânico desnecessário). Já o número mínimo de Falsos Negativos (alta taxa de Recall) atesta que o modelo é altamente seguro para a saúde pública, pois raramente deixa de alertar quando a qualidade do ar está, de fato, prejudicial.



A Área Sob a Curva (AUC) ilustra a capacidade do classificador de distinguir entre as classes. A curva do Random Forest Otimizado aproxima-se de forma quase contínua ao canto superior esquerdo, demonstrando uma capacidade superior aos modelos concorrentes na separação de distribuições da qualidade do ar.


6. Interpretabilidade do Modelo (Feature Importance e SHAP Values)

Algoritmos complexos como Random Forest são frequentemente chamados de "caixas pretas", deixando margem para ampla interpretação. Para atender ao critério de análise substantiva exigida pela avaliação, aplicamos métodos avançados de interpretabilidade geométrica.



A extração quantitativa das importâncias revelou que o modelo estabeleceu seus maiores limiares de corte em nós baseados nas variáveis PT08.S1(CO), CO(GT) e NOx(GT). Esta hierarquia de decisão não é um mero produto estatístico aleatório; ela possui total fundamentação no domínio do negócio da engenharia ambiental urbana por três fatores críticos:

- 1) O Peso do Monóxido de Carbono (CO(GT) e PT08.S1): O Monóxido de Carbono (CO) foi a variável balizadora para a criação do nosso alvo (target) binário. É natural e esperado que tanto a concentração química real medida em laboratório (CO(GT)) quanto a resposta de resistência elétrica gerada pelo sensor de óxido de estanho (PT08.S1(CO)) possuam o maior peso de divisão. O sensor físico PT08.S1 atua como um forte preditor substituto devido à sua alta sensibilidade à presença de gases redutores, servindo como uma "métrica de primeira linha" na árvore para separar dias de tráfego veicular intenso (ar "Ruim") de dias com atmosfera limpa (ar "Boa").
- 2) A Relevância Teórica dos Óxidos de Nitrogênio (NOx(GT)): Os óxidos de nitrogênio (compostos por NO e NO₂) figuram logo em seguida como grandes divisores de nós. No contexto da poluição atmosférica, o NOx é um subproduto direto da queima de combustíveis fósseis sob altas pressões e temperaturas, sendo emitido massivamente por escapamentos de veículos a diesel e gasolina. Como o NOx e o CO compartilham a mesma fonte geradora (o tráfego urbano), o modelo utiliza o NOx(GT) para refinar as ramificações das árvores, capturando picos onde o monóxido de carbono sozinho poderia gerar incerteza estatística.
- 3) O Impacto do Benzeno (C6H6(GT)): O benzeno é um hidrocarboneto aromático altamente volátil presente na composição da gasolina. Sua importância no modelo decorre do fato de que flutuações de C6H6(GT) servem como um traçador químico perfeito para o algoritmo identificar a presença de poluição estritamente industrial ou veicular primária, permitindo que o Random Forest isole anomalias causadas por outros fatores (como queimadas distantes ou poeira em suspensão) e foque no padrão de emissão urbana contínua.



Embora a Feature Importance tradicional mapeie quais variáveis são mais utilizadas para quebrar os nós das árvores, ela apresenta uma limitação severa: ela não informa a direção do impacto. O gráfico de barras nativo não esclarece se uma alta concentração de NOx(GT) torna o ar "Bom" ou "Ruim", apenas indica que a variável é importante.

Através do gráfico do SHAP inserido acima, nota-se como a interação do modelo acontece na prática: os pontos de coloração vermelha intensa (altos valores) para a feature NOx(GT) posicionam-se com forte impacto marginal positivo no eixo X. Isso explica estatisticamente que concentrações elevadas de Óxidos de Nitrogênio são gatilhos que forçam o algoritmo a classificar o ar daquele momento como "Ruim"

7. Análise Temporal e Sazonalidade (Resiliência Climatológica)

Um modelo aplicado ao Meio Ambiente não pode ser frágil a mudanças climáticas. Para garantir a robustez na produção, realizamos o particionamento das predições do modelo final sobre o conjunto de teste, dividindo os resultados por estação do ano:

- **Inverno (354 amostras):** Acurácia de 91,53% | F1-Score de 0,9133
- **Primavera (461 amostras):** Acurácia de 93,93% | F1-Score de 0,9378
- **Verão (301 amostras):** Acurácia de 96,01% | F1-Score de 0,9348
- **Outono (273 amostras):** Acurácia de 94,87% | F1-Score de 0,9586

O Random Forest manteve seu F1-Score acima de 91% ao longo de todo o ano. Como esperado pelas leis da meteorologia urbana, a menor estabilidade de acerto situou-se no Inverno (0.9133). Isso decorre de fenômenos atmosféricos como a inversão térmica e a escassez pluviométrica, que impedem a dispersão dos gases poluentes próximos à superfície e confundem a variação padrão dos sensores físicos. Por outro lado, o modelo cravou o seu pico de eficiência no Outono e na transição do Verão, períodos onde há maior clareza entre um dia chuvoso (ar disperso e "Bom") e o acúmulo em dias secos.

8. Exportação, Repositório e Implantação (Deploy)

A fase final da metodologia P2 consistiu em acoplar a arquitetura de dados preditiva em uma interface amigável para uso do público final.

Utilizando a biblioteca joblib, procedemos com o salvamento do modelo vencedora `modelo_qualidade_ar.pkl` em conjunto estrito com o normalizador estatístico `scaler_qualidade_ar.pkl`. O versionamento duplo de modelo e scaler garante que qualquer usuário no mundo possa introduzir seus próprios valores na aplicação em estado bruto, e o sistema internamente se encarregará de adequá-los matematicamente para o mesmo formato que as árvores de decisão viram durante a fase de treinamento em Python.

A aplicação (`app.py`) foi desenvolvida utilizando o framework Streamlit, provendo inputs paramétricos interativos e visualização instantânea da predição final de qualidade do ar. O código, em conjunto com o dataset referencial e as dependências (`requirements.txt`), foi versionado para um repositório Git público estruturado com a documentação em arquivo `README.md`.

O deploy do sistema web encontra-se ativo na infraestrutura do Streamlit Community Cloud em: <https://previsao-de-qualidade-do-ar-htr3agljavthx5ppztq7su.streamlit.app/>

9. Conclusão

O desenvolvimento deste projeto consolidou um ciclo íntegro de ML para classificação voltado para soluções socioambientais preditivas. A transição da P1 para a P2 representou maior maturidade algorítmica: o diagnóstico da curva de aprendizado permitiu calibrar os hiperparâmetros, eliminar o superajuste inicial e obter um F1-Score excelente de 93,6% em um cenário binário complexo e não balanceado.

A introdução de métodos de interpretabilidade, bem como a avaliação minuciosa do viés climático nas predições baseadas em estações, solidifica a segurança tecnológica do projeto.